TP Analyse causale de la survie : censure dépendante, confusion et risques compétitifs

David Hajage

Sommaire

Introduction **4**
Scénario . . . 4
Déroulement . . . 4
Structure du TP . . . 5
Comment utiliser ce TP . . . 5

Présentation des données **7**
Présentation . . . 7
Chargement et exploration . . . 8
Construire la base *baseline* . . . 10
Analyse brute (non ajustée) . . . 11

1 Partie 1 : confusion et censure dépendante **13**
1.1 Objectif . . . 13
1.2 Note sur la session R . . . 13
1.3 Étape 1 - Score de propension et poids IPTW . . . 14
1.4 Étape 2 - Kaplan-Meier pondéré (IPTW) . . . 14
1.5 Étape 3 - G-formula paramétrique . . . 15
1.6 Étape 4 - Censure dépendante : IPCW . . . 17
1.7 Étape 5 - Combiner IPTW et IPCW . . . 18
1.8 Discussion - comparaison des trois approches . . . 19

2 Partie 2 : risques compétitifs et estimands **20**
2.1 Objectif . . . 20
2.2 Note sur la session R . . . 20
2.3 Étape 1 - CIF naïve vs CIF correcte . . . 20
2.4 Étape 2 - Estimand 1 : effet total . . . 21
2.5 Étape 3 - Estimand 2 : risque net . . . 22
2.6 Étape 4 - Estimand 3 : effet séparable . . . 24
2.7 Récapitulatif . . . 24
2.8 Discussion . . . 25

3 Partie 3 : pondération (IPW) et décomposition **26**
3.1 Objectif . . . 26
3.2 Note sur la session R . . . 26
3.3 Étape 1 - Modèle de censure et poids IPCW . . . 26
3.4 Étape 2 - Poids “risque net” (censure × D) . . . 27
3.5 Étape 3 - Effet total et risque net, par IPW . . . 28
3.6 Étape 4 - Effet séparable, par IPW . . . 29
3.7 Étape 5 - Comparer g-formula et IPW . . . 29
3.8 Étape 6 - Décomposer l’effet total en direct + indirect . . . 30

4 Conclusion **31**
4.1 Récapitulatif : confusion et censure dépendante (Partie 1) 31
4.2 Récapitulatif : risques compétitifs et estimands (Parties 2 et 3) 31
4.3 Discussion 31
Ce que nous apprenons de chaque analyse 31
Pour vos protocoles 32

Introduction

Ce TP porte sur l'analyse causale des données de survie en présence de censure dépendante, de confusion et de risques compétitifs.

Scénario

Ce TP utilise les données de l'essai DES (Byar & Green), le même jeu de données que celui présenté dans la Partie 4 du cours. Il s'agit d'un essai randomisé historique chez des hommes atteints d'un cancer de la prostate avancé, comparant un traitement hormonal (DES, œstrogène de synthèse, 5 mg/jour, $A = 1$) à un placebo ($A = 0$). Des covariables baseline ($L_1, \dots, L_4$: activité, âge, hémoglobine, antécédent cardiovasculaire) sont mesurées à l'inclusion.

Deux évènements peuvent survenir au cours du suivi (analysé ici jusqu'à 36 mois) :

- Y : décès par cancer de la prostate (évènement d'intérêt) ;
- D : décès de toute autre cause, qui est un **risque compétitif** pour Y (une fois décédé, on ne peut plus mourir du cancer de la prostate).

Les patients encore vivants à la date de fin d'étude sont censurés (C) : il s'agit d'une censure administrative, que l'on traitera comme potentiellement dépendante des covariables.

> **Note**
>
> Cet essai étant **randomisé**, il n'y a en principe pas de confusion à corriger pour l'effet de A. Le TP pratique néanmoins l'IPTW à titre d'exercice (et comme vérification de cohérence : les poids devraient rester proches de 2, l'inverse de la probabilité d'être randomisé dans chaque bras), comme le signale le cours à la fin de la Partie 4. Tout ce qui est appris ici s'applique à l'identique dans une étude observationnelle.

Déroulement

> **Partie 1 - Confusion et censure dépendante**
>
> Pour commencer simplement, nous allons **temporairement ignorer l'existence du risque compétitif** D et le traiter comme une simple censure (simplification volontaire, comme dans les Parties 1 et 2 du cours). Cela permet de pratiquer l'IPTW, la g-formula paramétrique et l'IPCW sur un critère de survie classique, à un seul risque.
> Cette partie prépare la Partie 2.

Partie 2 - Risques compétitifs : quel estimand ?

Nous verrons pourquoi la simplification de la Partie 1 ne décrit pas ce qui arrive réellement, puis nous estimerons par g-formula les trois estimands possibles en présence d'un risque compétitif : l'effet total, le risque net et l'effet séparable (ce dernier sans essai à 4 bras).

Partie 3 - Pondération (IPW) et décomposition

Les trois mêmes estimands, estimés cette fois par pondération (IPW), puis la décomposition de l'effet total en effets direct et indirect séparables, comme dans la Partie 4 du cours.

Structure du TP

Partie	Méthode	Question	Durée estimée
Présentation	Analyse brute (Kaplan-Meier)	Description	~10 min
Partie 1	**IPTW, g-formula, IPCW**	Censure dépendante (risque compétitif ignoré, pour l'instant)	~25 min
Partie 2	**CIF, g-formula à deux hazards**	Risques compétitifs : effet total, risque net, effet séparable	~25 min
Partie 3	**IPW, décomposition**	Mêmes estimands par pondération, décomposition direct/indirect	~20 min
Conclusion	Synthèse	Comparaison des résultats	~5 min

Les durées annoncées sont approximatives, vous pourrez terminer chez vous ce que vous n'auriez pas eu le temps de faire aujourd'hui. Vous pouvez télécharger le pdf de ce TP et le fichier de données `df.csv` *via les liens tout en bas de cette page.*

Comment utiliser ce TP

Les exercices utilisent **WebR** : le code R s'exécute directement dans votre navigateur, sans installation. Si vous préférez, vous pouvez télécharger le fichier `df.csv` et exécuter les commandes dans une session locale de RStudio.

— Chaque bloc de code peut être modifié et exécuté avec le bouton **Run Code** (raccourci : `Ctrl+R` sur Windows, `Cmd+R` sur Mac).
— Les solutions peuvent être consultées librement. L'objectif est de suivre et de comprendre chaque étape, pas de réécrire le code à partir de rien : lisez-les, exécutez-les, modifiez-les.

— Les variables créées sur une page ne sont pas disponibles sur les pages suivantes ; elles sont reconstruites automatiquement dans chaque section (voir *Note sur la session R* au début de chaque partie).

Présentation des données

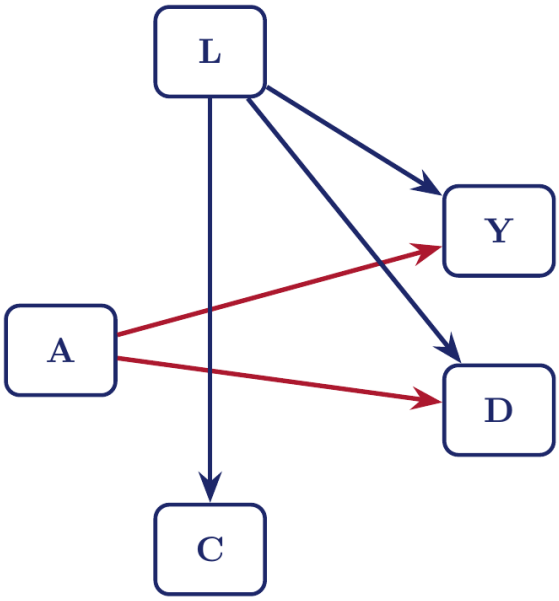
Présentation

Dans ce TP, nous utilisons les données de l'essai DES (Byar & Green), portant sur **252 patients** atteints d'un cancer de la prostate avancé, randomisés entre un traitement hormonal A (DES, œstrogène de synthèse, 5 mg/jour) et un placebo. L'objectif est d'évaluer l'effet de A sur le **décès par cancer de la prostate** Y (évènement d'intérêt), en présence d'un **risque compétitif** D (décès de toute autre cause) et d'une **censure** C (patient vivant à la fin de l'étude).

Les données sont au format **person-period** (une ligne par individu et par mois de suivi k), qui correspond aux notations en hazards discrets vues en cours.

Variable	Description
`id`	Identifiant patient
`k`	Période de suivi (mois)
`A`	Traitement à l'inclusion (0 = placebo, 1 = DES), **randomisé et fixé pour tout le suivi**
`L1`	Activité quotidienne réduite à l'inclusion (0/1)
`L2`	Tranche d'âge à l'inclusion (facteur à 3 niveaux : [0,60), [60,75), [75,100))
`L3`	Hémoglobine basse à l'inclusion, <12 (0/1)
`L4`	Antécédent cardiovasculaire à l'inclusion (0/1)
`Y`	Décès par cancer de la prostate pendant la période k (0/1) : **évènement d'intérêt**
`D`	Décès par une autre cause pendant la période k (0/1) : **risque compétitif** de Y
`C`	Censure (vivant à la fin de l'étude) survenue pendant la période k (0/1)

Le DAG ci-dessous résume les relations entre variables :



Lecture du DAG : A est **randomisé** (aucune flèche entrante) : il influence Y et D (en rouge). L (covariables baseline) influence Y, D et potentiellement C, mais pas A : ce n'est donc **pas** un facteur de confusion ici (contrairement à une étude observationnelle), même s'il reste utile de l'inclure dans les modèles pour la précision et pour la censure dépendante.

Chargement et exploration

Chargez les données et affichez les premières lignes. Vérifiez les dimensions de la base, le nombre d'individus, et le nombre total d'évènements Y et D.

```
#| context: interactive
library(survival)
library(dplyr)
df <- read.csv("df.csv")

## Affichez les premières lignes, les dimensions, le nombre d'individus,
## le nombre de lignes où Y = 1 et le nombre de lignes où D = 1
```

{**Correction :**}

```
library(survival)
library(dplyr)
df <- read.csv("df.csv")

head(df)
dim(df)                  # dimensions de la base
length(unique(df$id))    # nombre d'individus
sum(df$Y)                # nombre d'evenements d'interet (deces par cancer)
```

```r
sum(df$D)                # nombre de deces par une autre cause (risque competitif)
df |> filter(id %in% unique(df$id)[1:2]) |> group_by(id) |>
  slice_head(n = 3) |> ungroup()  # 3 premiers mois des 2 premiers individus
```

```
  id k A L1      L2 L3 L4 Y D C
1  3 1 1  0 [60,75)  0  1 0 0 0
2  3 2 1  0 [60,75)  0  1 0 0 0
3  3 3 1  0 [60,75)  0  1 0 0 0
4  3 4 1  0 [60,75)  0  1 0 0 0
5  3 5 1  0 [60,75)  0  1 0 0 0
6  3 6 1  0 [60,75)  0  1 0 0 0
```

```
[1] 8865   10
```

```
[1] 252
```

```
[1] 64
```

```
[1] 124
```

```
# A tibble: 6 x 10
     id     k     A    L1 L2         L3    L4     Y     D     C
  <int> <int> <int> <int> <chr>   <int> <int> <int> <int> <int>
1     3     1     1     0 [60,75)     0     1     0     0     0
2     3     2     1     0 [60,75)     0     1     0     0     0
3     3     3     1     0 [60,75)     0     1     0     0     0
4     5     1     0     0 [60,75)     0     0     0     0     0
5     5     2     0     0 [60,75)     0     0     0     0     0
6     5     3     0     0 [60,75)     0     0     0     0     0
```

La base comporte 8865 lignes, 252 individus distincts, 64 décès par cancer de la prostate et 124 décès par une autre cause.

> **Note**
>
> **Format person-period : chaque individu a autant de lignes que de mois suivis avant l'évènement, le décès, la censure, ou la fin d'étude. La dernière ligne d'un individu indique son statut final (Y, D, ou C à 1 si l'évènement correspondant est survenu pendant cette période).**

Construire la base *baseline*

Pour les analyses de cette première partie du TP, il est pratique de résumer les données en une ligne par individu, avec le statut final et le temps de suivi total.

Créez `df_base` contenant : `id`, `A`, `L1`-`L4` (valeurs baseline, constantes pour chaque individu), `time` (dernière valeur de `k`, c'est-à-dire le nombre de mois suivis), `Y`, `D`, `C` (statuts à la dernière période observée).

```
#| context: interactive
## Créez df_base : une ligne par individu, avec A, L1-L4 (baseline),
## time (derniere valeur de k), et les statuts finaux Y, D, C
```

{Correction :}

```
## On resume df (format person-period) en une ligne par individu :
## - first() pour les covariables baseline (constantes pour un individu donne)
## - last() pour le temps de suivi total et les statuts finaux
df_base <- df |>
  group_by(id) |>
  summarise(
    A    = first(A),
    L1   = first(L1), L2 = first(L2), L3 = first(L3), L4 = first(L4),
    time = last(k),   # nombre de mois suivis
    Y    = last(Y),
    D    = last(D),
    C    = last(C)
  ) |>
  ungroup()

head(df_base)
nrow(df_base)  # doit valoir le nombre d'individus distincts
```

```
# A tibble: 6 x 10
     id     A    L1 L2          L3    L4  time     Y     D     C
  <int> <int> <int> <chr>    <int> <int> <int> <int> <int> <int>
1     3     1     0 [60,75)      0     1    40     0     1     0
2     5     0     0 [60,75)      0     0    65     0     0     1
3     7     0     0 [75,100)     0     0    46     0     1     0
4     8     0     0 [60,75)      0     1    62     0     0     1
5    12     1     0 [60,75)      0     1    59     0     0     1
6    14     0     0 [0,60)       0     1    49     1     0     0
```

```
[1] 252
```

Analyse brute (non ajustée)

Avant tout ajustement, et en ignorant pour l'instant le risque compétitif D (traité comme une censure, comme si Y était le seul évènement possible), comparons les courbes de survie selon A.

Tracez les courbes de Kaplan-Meier de l'évènement Y selon A (traitez D et C comme des censures pour l'instant), puis extrayez la survie estimée à 36 mois dans chaque groupe.

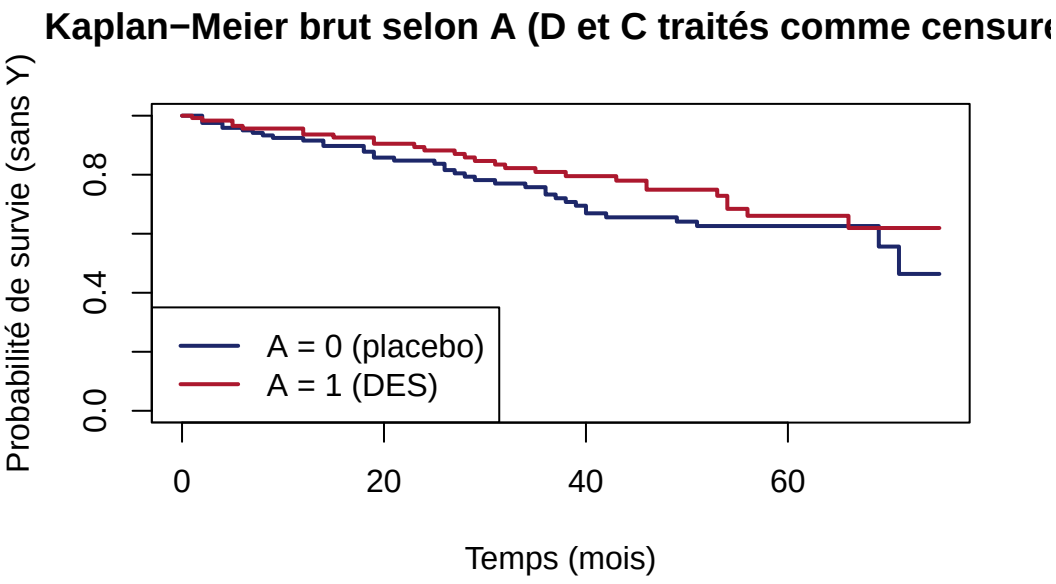
```
#| context: interactive
## Surv(time, Y) : Y = 1 si evenement d'interet, 0 sinon (censure, y compris D et C
## pour l'instant : c'est une simplification qu'on lèvera en Partie 2)
```

{Correction :}

```
km_brut <- survfit(Surv(time, Y) ~ A, data = df_base)

plot(km_brut,
     col  = c("#1D2769", "#AC182E"), lwd = 2,
     xlab = "Temps (mois)", ylab = "Probabilité de survie (sans Y)",
     main = "Kaplan-Meier brut selon A (D et C traités comme censure)")
legend("bottomleft",
       legend = c("A = 0 (placebo)", "A = 1 (DES)"),
       col = c("#1D2769", "#AC182E"), lwd = 2)

## Survie a 36 mois
summary(km_brut, times = 36)
```




```
Call: survfit(formula = Surv(time, Y) ~ A, data = df_base)

                A=0
```

```
        time       n.risk      n.event     survival      std.err lower 95% CI
      36.000       61.000       27.000        0.733        0.045        0.650
upper 95% CI
       0.827

                A=1
        time       n.risk      n.event     survival      std.err lower 95% CI
     36.0000      60.0000      18.0000       0.8093       0.0411       0.7326
upper 95% CI
      0.8940
```

Que constatez-vous ? Cette différence brute a-t-elle une interprétation causale ?

Réponse

On observe une différence de survie entre les groupes $A = 0$ et $A = 1$. Comme A est randomisé, cette différence brute a bien une interprétation causale sur "Y traité comme seul évènement possible". Ce n'est cependant pas la bonne quantité à regarder : D (décès par une autre cause) est un risque compétitif, pas une censure ordinaire. Le traiter comme une censure suppose implicitement que les personnes décédées d'une autre cause auraient pu, plus tard, mourir du cancer de la prostate.
La Partie 1 pratique IPTW, g-formula et IPCW sur cette même simplification (utile même en essai randomisé, pour la censure dépendante et par souci d'exercice). La Partie 2 montrera comment estimer correctement le risque de Y en tenant compte de D comme risque compétitif.

1 Partie 1 : confusion et censure dépendante

1.1 Objectif

Cette partie pratique l'IPTW, la g-formula et l'IPCW sur les données de l'essai DES. On estime les courbes de survie contrefactuelles :

$$S^{a=1}(t) = \Pr(T^{a=1} > t) \quad \textbf{et} \quad S^{a=0}(t) = \Pr(T^{a=0} > t)$$

> **Note**
>
> **Simplification volontaire : dans toute cette partie, le risque compétitif D est traité comme une simple censure (on ignore volontairement qu'il rend Y impossible à observer). C'est la simplification faite dans les Parties 1 et 2 du cours, avant d'introduire les risques compétitifs en Partie 3. La Partie 2 de ce TP montrera pourquoi cette simplification n'est pas satisfaisante pour l'évènement d'intérêt, mais nous verrons aussi qu'elle correspond en réalité à un estimand valide : le risque net (Partie 2).**
> **Rappel : A est ici randomisé, donc l'IPTW n'est pas strictement nécessaire pour corriger une confusion (il n'y en a pas). On le pratique quand même : c'est un bon exercice, et un bon test de cohérence (les poids devraient être proches de 2, l'inverse de la probabilité d'être randomisé dans chaque bras, et peu changer les résultats).**

1.2 Note sur la session R

Les variables suivantes sont disponibles dans vos chunks interactifs (construites dans le contexte de setup) :

- **`df` : base au format person-period (une ligne par individu et par mois)**
- **`df_base` : une ligne par individu, avec `A`, `L1`-`L4` (baseline), `time`, `Y`, `D`, `C` (statuts finaux)**

```
# A tibble: 6 x 10
     id     A    L1 L2          L3    L4  time     Y     D     C
  <int> <int> <int> <chr>    <int> <int> <int> <int> <int> <int>
1     3     1     0 [60,75)      0     1    40     0     1     0
2     5     0     0 [60,75)      0     0    65     0     0     1
3     7     0     0 [75,100)     0     0    46     0     1     0
4     8     0     0 [60,75)      0     1    62     0     0     1
5    12     1     0 [60,75)      0     1    59     0     0     1
6    14     0     0 [0,60)       0     1    49     1     0     0
```

1.3 Étape 1 - Score de propension et poids IPTW

Estimez le score de propension $e(L) = \Pr(A = 1 \mid L)$ ***par régression logistique (sur*** `L1 + L2 + L3 + L4`***), puis calculez les poids IPTW pour l'ATE.***

```
#| context: interactive
## Modele de score de propension : A ~ L1 + L2 + L3 + L4
## Poids IPTW : 1 / e(L) si A=1, 1 / (1-e(L)) si A=0
```

{Correction :}

```
ps_mod <- glm(A ~ L1 + L2 + L3 + L4, data = df_base, family = binomial)
df_base$e_hat <- predict(ps_mod, type = "response")

## Poids IPTW pour l'ATE : inverse de la probabilite du traitement recu
df_base$w_iptw <- ifelse(df_base$A == 1,
                         1 / df_base$e_hat,
                         1 / (1 - df_base$e_hat))

summary(df_base$w_iptw)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.624   1.824   1.974   2.000   2.128   2.603
```

Réponse

Comme A est randomisé, les poids sont resserrés autour de 2, soit l'inverse de la probabilité d'être randomisé dans chaque bras (pas de confusion réelle à corriger) : c'est le comportement attendu sur un essai randomisé, et un bon signe que le modèle de score de propension ne fait rien d'anormal.

1.4 Étape 2 - Kaplan-Meier pondéré (IPTW)

Calculez le Kaplan-Meier pondéré par `w_iptw` ***(toujours en traitant*** D ***et*** C ***comme des censures), et comparez la survie à 36 mois entre les deux groupes.***

```
#| context: interactive
## survfit(..., weights = df_base$w_iptw)
```

{Correction :}

```
km_iptw <- survfit(Surv(time, Y) ~ A, data = df_base, weights = w_iptw)
summary(km_iptw, times = 36)
```

```
Call: survfit(formula = Surv(time, Y) ~ A, data = df_base, weights = w_iptw)

               A=0
       time       n.risk      n.event     survival      std.err lower 95% CI
    36.0000     122.3848      53.2070       0.7361       0.0448       0.6534
upper 95% CI
      0.8293

               A=1
       time       n.risk      n.event     survival      std.err lower 95% CI
    36.0000     119.5418      36.8837       0.8051       0.0419       0.7270
upper 95% CI
      0.8915
```

Le Kaplan-Meier pondéré reste un produit de (1 - hazard pondéré). Il repose sur les mêmes hypothèses d'identifiabilité qu'un Kaplan-Meier stratifié, mais sur une seule pseudo-population.

1.5 Étape 3 - G-formula paramétrique

Plutôt que de pondérer, on peut modéliser directement le hazard discret de Y en fonction de A, L et de la période k, puis moyenner les prédictions sur toute la population.

Ajustez un modèle logistique poolé sur les lignes de `df` où l'individu est encore à risque de Y, c'est-à-dire sans D ni C (`subset(df, D == 0 & C == 0)`) : `Y ~ A * k + L1 + L2 + L3 + L4`.

Pourquoi retirer les lignes où $D = 1$? Par convention, dans chaque mois, la censure et D surviennent avant Y : un patient décédé d'une autre cause au mois k n'a donc pas été à risque de Y pendant ce mois. Garder sa ligne avec $Y = 0$ compterait un mois entier sans évènement, et sous-estimerait légèrement le hazard de Y.

```
#| context: interactive
## Modele de hazard poole : Y ~ A * k + L1 + L2 + L3 + L4,
## sur les lignes encore a risque de Y : subset(df, D == 0 & C == 0)
```

{Correction :}

```
## Modele de hazard discret, poole sur toutes les periodes ou l'individu est
## encore a risque de Y (ni D ni C survenu pendant la periode)
haz_mod <- glm(Y ~ A * k + L1 + L2 + L3 + L4,
               data = subset(df, D == 0 & C == 0), family = binomial)
summary(haz_mod)
```

```
Call:
glm(formula = Y ~ A * k + L1 + L2 + L3 + L4, family = binomial,
    data = subset(df, D == 0 & C == 0))

Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept) -4.620436   0.460378 -10.036   <2e-16 ***
A           -0.500930   0.462733  -1.083   0.2790
k            0.002587   0.009093   0.285   0.7760
L1           1.151662   0.362770   3.175   0.0015 **
L2[60,75)   -0.442275   0.403706  -1.096   0.2733
L2[75,100)  -0.051695   0.432719  -0.119   0.9049
L3           0.391956   0.316945   1.237   0.2162
L4          -0.527921   0.302594  -1.745   0.0810 .
A:k          0.008538   0.013851   0.616   0.5376
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 755.95  on 8676  degrees of freedom
Residual deviance: 738.85  on 8668  degrees of freedom
AIC: 756.85

Number of Fisher Scoring iterations: 8
```

Pour chaque individu, prédisez son hazard à chaque période sous $A = 1$ puis sous $A = 0$, et chaînez les $(1-hazard)$ pour obtenir sa survie contrefactuelle individuelle à 36 mois. Moyennez ensuite sur tous les individus.

```
#| context: interactive
## Pour k = 1, ..., 36 : predire le hazard sous A=1 et sous A=0 pour chaque
## individu de df_base (avec ses valeurs de L1-L4), puis cumuler prod(1 - hazard)
```

{Correction :}

```r
K <- 36
predict_gform <- function(a_val) {
  surv <- rep(1, nrow(df_base))  # survie cumulee, une valeur par individu
  for (kk in 1:K) {
    newdata <- data.frame(A = a_val, k = kk,
                          L1 = df_base$L1, L2 = df_base$L2,
                          L3 = df_base$L3, L4 = df_base$L4)
    haz <- predict(haz_mod, newdata = newdata, type = "response")
    surv <- surv * (1 - haz)
  }
  surv  # = S^a(36) individuel, sous le scenario A = a_val
}

s1_gform <- predict_gform(1)  # survie individuelle predite sous A=1
s0_gform <- predict_gform(0)  # survie individuelle predite sous A=0
```

```r
## Moyenne sur toute la population : estimation de S^a=1(36) et S^a=0(36)
c(S1 = mean(s1_gform), S0 = mean(s0_gform))
```

```
       S1        S0
0.8030453 0.7394262
```

On retrouve l'algorithme de G-computation vu en cours, appliqué période par période : ajuster un modèle de hazard, prédire sous chaque scénario, chaîner les (1 - hazard), moyenner sur la population.

1.6 Étape 4 - Censure dépendante : IPCW

Modélisez** $\Pr(C = 1 \mid A, L)$ **par régression logistique poolée, puis calculez le poids IPCW cumulé pour chaque période de suivi.

Sur quelle période ajuster le modèle de censure ?

Dans ces données, personne n'est censuré avant le mois 51 (vérifiez : `range(df$k[df$C == 1])`). Ajuster le modèle de censure sur tout le suivi (mois 1 à 75) reviendrait à estimer un risque de censure y compris sur des mois où, empiriquement, cet évènement ne s'est jamais produit : le risque estimé serait dilué vers une valeur trop faible, et les poids IPCW seraient légèrement biaisés, y compris tôt dans le suivi, là où aucune correction n'est nécessaire.
La bonne pratique consiste donc à restreindre l'ajustement du modèle à la période réellement à risque (ici $k > 50$), et à fixer le poids à 1 avant cette période. C'est le choix fait dans le cours (Partie 4), inspiré de l'atelier de la Society for Epidemiologic Research sur les risques compétitifs (Rojas-Saunero et al.), sur ce même jeu de données.
Si la censure survenait au contraire de façon à peu près uniforme tout au long du suivi (situation plus classique), un modèle unique ajusté sur toute la période, sans restriction, serait le bon choix (c'est le code le plus souvent rencontré dans la littérature). Le premier encart ci-dessous montre l'approche retenue ici ; le second montre cette variante "classique", pour une situation où la censure ne serait pas concentrée en fin de suivi.

À 36 mois, les poids IPCW valent tous 1

Nos analyses s'arrêtent à 36 mois, et la première censure survient au mois 51 : sur la fenêtre analysée, personne n'est censuré et tous les poids IPCW valent 1. L'IPCW ne modifie donc aucun résultat de ce TP (l'Étape 5 donnera exactement les mêmes chiffres que l'IPTW seul). Ces censures tardives correspondent d'ailleurs à des patients vivants à la date de fin d'étude (censure administrative), et non à des sorties d'étude liées à leur état de santé.
Allonger l'horizon n'apporterait rien : à 60 ou 72 mois, l'IPCW ne déplace la différence de survie que d'environ 0,001, alors qu'il ne reste que 52 puis 12 patients à risque et que les estimations deviennent instables. On construit donc ces poids ici à titre d'exercice : le code est celui que vous utiliseriez face à une vraie censure dépendante.

```
#| context: interactive
## Modele de censure, restreint a la periode reellement a risque (ici k > 50 :
## personne n'est censure avant, cf. range(df$k[df$C == 1]))
## Poids IPCW a la periode k pour l'individu i :
##   produit, de la 1ere periode a k, de 1 / (1 - p_C(A_i, L_i))
```

{Correction :}

```
## Modele de la censure, restreint a la periode reellement a risque
late <- subset(df, k > 50)
cens_mod <- glm(C ~ A + L1 + L2 + L3 + L4, data = late, family = binomial)
df$p_cens <- 0
df$p_cens[df$k > 50] <- predict(cens_mod, newdata = df[df$k > 50, ], type = "response")

## Poids IPCW cumule : produit de 1/(1 - p_cens) depuis la 1ere periode jusqu'a la
## periode courante (chaque individu contribue une ligne par periode a risque)
df <- df |>
  group_by(id) |>
  mutate(w_ipcw = cumprod(1 / (1 - p_cens))) |>
  ungroup()

summary(df$w_ipcw)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.000   1.000   1.000   1.105   1.000   5.150
```

Variante “classique” : censure uniforme sur tout le suivi

Si la censure ne se concentrait pas en fin de suivi, on ajusterait un seul modèle sur l’ensemble des périodes, sans restriction :

```
## Version "classique", sans restriction de periode - a utiliser si la censure
## survient de facon a peu pres uniforme tout au long du suivi (PAS le cas ici)
cens_mod <- glm(C ~ A + L1 + L2 + L3 + L4, data = df, family = binomial)
df$p_cens <- predict(cens_mod, type = "response")
```

Appliqué à nos données, ce code “classique” attribuerait, y compris avant le mois 51, une petite probabilité de censure purement due à l’extrapolation du modèle en dehors de la période où l’évènement a réellement été observé, ce qui biaiserait légèrement les poids même tôt dans le suivi, là où ils devraient valoir 1.

1.7 Étape 5 - Combiner IPTW et IPCW

Multipliez le poids IPTW (baseline) et le poids IPCW (période par période), puis calculez le Kaplan-Meier pondéré sur les données au format “compteur” (`Surv(k-1, k, Y)`).

```
#| context: interactive
## Fusionner w_iptw (df_base) dans df, calculer le poids total = w_iptw * w_ipcw
## puis survfit(Surv(k-1, k, Y) ~ A, data = df, weights = poids_total)
```

{Correction :}

```
df_w <- df |>
  left_join(df_base[, c("id", "w_iptw")], by = "id") |>
  mutate(poids_total = w_iptw * w_ipcw)

## Format "compteur" : chaque ligne est l'intervalle [k-1, k) avec son propre poids
km_combine <- survfit(Surv(k - 1, k, Y) ~ A, data = df_w, weights = poids_total)
summary(km_combine, times = 36)
```

```
Call: survfit(formula = Surv(k - 1, k, Y) ~ A, data = df_w, weights = poids_total)

                A=0
        time       n.risk      n.event     survival      std.err lower 95% CI
     36.0000     122.3848      53.2070       0.7361       0.0446       0.6537
upper 95% CI
      0.8290

                A=1
        time       n.risk      n.event     survival      std.err lower 95% CI
      36.000      119.542       36.884        0.805        0.042        0.727
upper 95% CI
       0.892
```

1.8 Discussion - comparaison des trois approches

Comparez la différence de survie à 36 mois ($S^{a=1}(36) - S^{a=0}(36)$) ***obtenue par l'analyse brute (Présentation), l'IPTW seul, la g-formula, et IPTW+IPCW combinés.***

Réponse

Sur cet essai randomisé, les quatre approches donnent des estimations proches : il n'y a pas de confusion réelle à corriger, donc l'IPTW ne change presque rien. L'IPCW ne change rien du tout ici, puisque personne n'est censuré avant 36 mois. Dans d'autres données, en revanche, une censure dépendante de L pourrait faire une différence, même en essai randomisé. Ceci reste vrai bien que nous ayons, dans toute cette partie, traité le risque compétitif D comme une simple censure : la Partie 2 va maintenant examiner les conséquences de cette simplification.

2 Partie 2 : risques compétitifs et estimands

2.1 Objectif

Dans la Partie 1, nous avons volontairement traité le risque compétitif D (décès par une autre cause) comme une simple censure. Cette partie montre pourquoi ce n'est pas satisfaisant en général pour décrire ce qui arrive réellement à la population, introduit la fonction d'incidence cumulée (CIF) correcte, et estime par g-formula les trois estimands possibles en présence de risques compétitifs (l'effet séparable ne nécessite pas d'essai à 4 bras).

2.2 Note sur la session R

Les variables suivantes sont disponibles (reconstruites dans le contexte de setup) :

- **`df` : base person-période ; `df_base` : une ligne par individu**
- **`haz_mod_Y` : le modèle de hazard de Y, déjà ajusté (voir l'encart ci-dessous pour sa forme exacte, un peu plus riche que celle utilisée en Partie 1)**

> **La forme de l'effet du temps est un choix de spécification**
>
> **En Partie 1, le hazard de Y dépendait de k de façon simplement linéaire (`A * k`), pour une première prise en main. À partir de maintenant, on reprend la spécification utilisée dans les diapos du cours (Partie 4) pour le modèle de Y :**
>
> ```
> Y ~ A + k + I(k^2) + I(k^3) + A:k + A:I(k^2) + L1 + L2 + L3 + L4
> ```
>
> **Un polynôme de degré 3 en k (avec des interactions avec A) permet au hazard de suivre une forme plus flexible au cours du temps, plutôt qu'une tendance strictement linéaire (ou constante). Ce choix n'est pas imposé : il s'ajuste selon la richesse des données disponibles (nombre d'évènements, longueur du suivi). On peut aussi bien le complexifier (degré plus élevé, splines) que le simplifier (linéaire, voire un hazard constant dans le temps), tant que la forme retenue capture raisonnablement bien comment le risque évolue au cours du suivi.**

2.3 Étape 1 - CIF naïve vs CIF correcte

Construisez la variable de statut à 3 niveaux (`censore`, `evenement`, `deces`), puis comparez l'incidence cumulée de Y obtenue en traitant D comme une censure (naïve) à celle obtenue par l'estimateur d'Aalen-Johansen (qui prend en compte D comme risque compétitif).

```
#| context: interactive
## Statut a 3 niveaux : "censore" (ni Y ni D), "evenement" (Y=1), "deces" (D=1)
## Le premier niveau du facteur doit etre l'etat de reference (censure)
```

```
## CIF naive : survfit(Surv(time, Y) ~ 1, data = df_base) puis 1 - survie
## CIF correcte : survfit(Surv(time, statut) ~ 1, data = df_base) (Aalen-Johansen)
```

{Correction :}

```
df_base$statut <- factor(
  ifelse(df_base$Y == 1, "evenement", ifelse(df_base$D == 1, "deces", "censore")),
  levels = c("censore", "evenement", "deces")
)

## CIF naive (D traite comme une censure, comme en Partie 1)
km_naif <- survfit(Surv(time, Y) ~ 1, data = df_base)
cif_naive_36 <- 1 - summary(km_naif, times = 36)$surv

## CIF correcte (Aalen-Johansen, prend en compte D comme risque competitif)
aj <- survfit(Surv(time, statut) ~ 1, data = df_base)
s_aj <- summary(aj, times = 36)
cif_correcte_36 <- s_aj$pstate[, colnames(s_aj$pstate) == "evenement"]

c(naive = cif_naive_36, correcte = cif_correcte_36)
```

```
     naive correcte.evenement
 0.2304537          0.1785714
```

Réponse

La CIF naïve (qui traite D comme une censure) est plus élevée que la CIF correcte (Aalen-Johansen) : en supposant implicitement que les personnes décédées auraient pu faire l'évènement d'intérêt plus tard, elle surestime l'incidence de Y.

2.4 Étape 2 - Estimand 1 : effet total

Le premier estimand compare directement le risque de Y tel qu'il se produit réellement (risque compétitif inclus) entre les deux groupes de traitement.

$$\Pr(Y_k^{a=1} = 1) - \Pr(Y_k^{a=0} = 1)$$

Comme en Partie 1, on modélise le hazard de Y (`haz_mod_Y`, déjà ajusté), et on ajoute maintenant un second modèle pour le hazard de D. On chaîne les deux hazards :

$$\hat{S}_i(k) = \prod_{j<k} \{1 - \hat{\lambda}_{D,i}(j)\}\{1 - \hat{\lambda}_{Y,i}(j)\}, \qquad \widehat{\mathbf{CIF}}_{Y,i}(k) = \sum_{j \le k} \hat{S}_i(j)\{1 - \hat{\lambda}_{D,i}(j)\}\hat{\lambda}_{Y,i}(j)$$

Ajustez le modèle de hazard de D (`D ~ A + k + I(k^2) + L1 + L2 + L3 + L4`, sur les lignes non censurées), puis écrivez une fonction `gcomp_CIF(a_Y, a_D)` qui prédit et chaîne les deux hazards

pour chaque individu (sous $A = a_Y$ pour le modèle de Y, sous $A = a_D$ pour le modèle de D), et retourne la CIF moyenne à 36 mois.

```
#| context: interactive
## Modele de hazard de D : D ~ A + k + I(k^2) + L1 + L2 + L3 + L4, sur les lignes
## non censurees (subset(df, C == 0))

## gcomp_CIF <- function(a_Y, a_D) { ... }
## Chainer les deux hazards prediction par prediction, comme dans la formule
## ci-dessus, individu par individu, puis moyenner
```

{Correction :}

```
haz_mod_D <- glm(D ~ A + k + I(k^2) + L1 + L2 + L3 + L4,
                 data = subset(df, C == 0), family = binomial)

K <- 36
gcomp_CIF <- function(a_Y, a_D) {
  Spred <- rep(1, nrow(df_base)); CIF <- rep(0, nrow(df_base))
  for (kk in 1:K) {
    newD <- data.frame(A = a_D, k = kk, L1 = df_base$L1, L2 = df_base$L2,
                       L3 = df_base$L3, L4 = df_base$L4)
    newY <- data.frame(A = a_Y, k = kk, L1 = df_base$L1, L2 = df_base$L2,
                       L3 = df_base$L3, L4 = df_base$L4)
    hazD <- predict(haz_mod_D, newdata = newD, type = "response")
    hazY <- predict(haz_mod_Y, newdata = newY, type = "response")
    CIF   <- CIF + Spred * (1 - hazD) * hazY
    Spred <- Spred * (1 - hazD) * (1 - hazY)
  }
  mean(CIF)
}

## Effet total : les deux hazards varient ENSEMBLE avec A
effet_total <- gcomp_CIF(1, 1) - gcomp_CIF(0, 0)
effet_total
```

```
[1] -0.06675082
```

Cet estimand mélange l'effet du traitement sur Y et son effet (éventuel) sur le risque compétitif D : c'est un effet total, et non un effet propre sur Y.

2.5 Étape 3 - Estimand 2 : risque net

Le deuxième estimand répond à une autre question : quel serait le risque de Y dans un monde hypothétique où le risque compétitif D serait éliminé ?

$$\Pr(Y_k^{a=1,d=0} = 1) - \Pr(Y_k^{a=0,d=0} = 1)$$

Note

Vous avez déjà estimé cet estimand en Partie 1 (Étape 3), avec un modèle plus simple. La g-formula qui modélise le hazard de Y sans référence à D est l'estimateur du risque net, à condition d'avoir ajusté sur les causes communes de D et Y (ici, L_1-L_4). Avec la fonction `gcomp_CIF` de l'étape précédente, c'est équivalent à ne jamais appeler le modèle de D (hazard de D forcé à 0).

Écrivez cette version simplifiée, `gcomp_CIF0(a_Y)`, qui ne modélise jamais D.

```
#| context: interactive
## gcomp_CIF0 <- function(a_Y) { comme gcomp_CIF, mais hazD force a 0 partout }
```

{Correction :}

```
gcomp_CIF0 <- function(a_Y) {
  Spred <- rep(1, nrow(df_base)); CIF <- rep(0, nrow(df_base))
  for (kk in 1:K) {
    newY <- data.frame(A = a_Y, k = kk, L1 = df_base$L1, L2 = df_base$L2,
                       L3 = df_base$L3, L4 = df_base$L4)
    hazY <- predict(haz_mod_Y, newdata = newY, type = "response")
    CIF   <- CIF + Spred * hazY
    Spred <- Spred * (1 - hazY)
  }
  mean(CIF)
}

## Risque net : le modele de D n'est JAMAIS utilise
risque_net <- gcomp_CIF0(1) - gcomp_CIF0(0)
risque_net
```

```
[1] -0.06798562
```

Comparez cette différence de risque net à la différence d'effet total obtenue à l'Étape 2 : sont-elles identiques ?

Réponse

Les deux différences ne sont, en général, pas identiques : le traitement A affecte à la fois le hazard de Y et le hazard de D (le DES augmente le risque de décès par une autre cause). L'effet total mélange ces deux mécanismes, tandis que le risque net les sépare artificiellement en simulant un monde sans risque compétitif. Aucune des deux n'est "la bonne" réponse dans l'absolu : elles répondent à des questions différentes (cf. cours, Partie 3).

2.6 Étape 4 - Estimand 3 : effet séparable

Le troisième estimand isole la composante de A qui agit sur Y seul, à hazard de D fixé (neutralisé) plutôt qu'éliminé :

$$\Pr(Y_k^{a_Y=1,\,a_D=0}=1)-\Pr(Y_k^{a_Y=0,\,a_D=0}=1)$$

> **! Important**
>
> **Cet estimand ne nécessite pas d'essai à 4 bras : on réutilise les deux mêmes modèles de hazard (`haz_mod_D`, `haz_mod_Y`), avec la même fonction `gcomp_CIF(a_Y, a_D)` qu'à l'Étape 2, en lui donnant deux valeurs différentes pour a_Y et a_D.**

Avec `gcomp_CIF`, calculez gcomp_CIF$(1,0)$ − gcomp_CIF$(0,0)$: le hazard de D reste fixé à $A=0$ dans les deux termes, seul celui de Y change de bras.

```
#| context: interactive
## gcomp_CIF(1, 0) - gcomp_CIF(0, 0)
```

{Correction :}

```
## Effet separable : hazard de D FIXE a a_D = 0, seul celui de Y varie
effet_separable <- gcomp_CIF(1, 0) - gcomp_CIF(0, 0)
effet_separable
```

```
[1] -0.05538297
```

2.7 Récapitulatif

Rassemblez les trois différences de risque à 36 mois (effet total, risque net, effet séparable) dans un seul tableau.

{Correction :}

```
data.frame(
  Estimand = c("Effet total", "Risque net", "Effet separable"),
  Difference_de_risque = round(c(effet_total, risque_net, effet_separable), 3)
)
```

```
         Estimand Difference_de_risque
1     Effet total               -0.067
2      Risque net               -0.068
3 Effet separable               -0.055
```

2.8 Discussion

! Ce qu'il faut retenir

La CIF naïve (traiter le risque compétitif comme une censure) surestime le risque de l'évènement d'intérêt. Une fois la CIF correctement estimée, il reste à choisir entre plusieurs estimands (effet total, risque net, effet séparable), qui répondent à des questions cliniques différentes et peuvent donner des conclusions différentes. Les trois s'estiment avec les deux mêmes modèles de hazard, combinés différemment.

3 Partie 3 : pondération (IPW) et décomposition

3.1 Objectif

Cette partie reproduit les trois mêmes estimands que la Partie 2 (effet total, risque net, effet séparable), mais par pondération (IPW) plutôt que par g-formula, comme dans la Partie 4 du cours. Elle termine par la décomposition de l'effet total en effet direct + effet indirect séparables.

3.2 Note sur la session R

- `df` : base person-period (reconstruite dans le contexte de setup)
- `K <- 36` : nombre de périodes de suivi

3.3 Étape 1 - Modèle de censure et poids IPCW

Modélisez $\Pr(C = 1 \mid A, L)$ ***et calculez le poids IPCW cumulé (poids "effet total").***

> **Rappel : restreindre le modèle de censure à la période à risque**
>
> **Comme en Partie 1, personne n'est censuré avant le mois 51 dans ces données (`range(df$k[df$C == 1])`) : on ajuste donc le modèle de censure uniquement sur $k > 50$, et on fixe le poids à 1 avant cette période. La variante "classique" (un seul modèle sur tout le suivi, sans restriction) est rappelée à la fin de cette étape : c'est celle qu'il faudrait utiliser si la censure survenait de façon uniforme tout au long du suivi.**
> **Comme en Partie 1, ces poids valent 1 sur toute la fenêtre analysée (36 mois) : `w_total` ne modifie donc pas les résultats, et `w_net` se réduit au poids lié à D.**

```
#| context: interactive
## Modele de censure, restreint a la periode reellement a risque (k > 50) :
## C ~ A + L1 + L2 + L3 + L4, sur df
## Poids IPCW cumule (produit de 1/(1-p_cens) periode par periode, par individu)
```

{Correction :}

```
late <- subset(df, k > 50)
modC <- glm(C ~ A + L1 + L2 + L3 + L4, data = late, family = binomial)
df$predC <- 1
df$predC[df$k > 50] <- 1 - predict(modC, newdata = df[df$k > 50, ], type = "response")
df <- df |>
  group_by(id) |>
```

```
  mutate(cumPredC = cumprod(predC)) |>
  ungroup()

w_total <- 1 / df$cumPredC          # poids "effet total" : censure seule
summary(w_total)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.000   1.000   1.000   1.105   1.000   5.150
```

Variante "classique" : censure uniforme sur tout le suivi

```
## Version "classique", sans restriction de periode - a utiliser si la censure
## survient de facon a peu pres uniforme tout au long du suivi (PAS le cas ici)
modC <- glm(C ~ A + L1 + L2 + L3 + L4, data = df, family = binomial)
df$predC <- 1 - predict(modC, type = "response")
```

3.4 Étape 2 - Poids "risque net" (censure × D)

Pour le risque net, D est traité comme une seconde censure : on multiplie le poids IPCW par un poids qui gère la sortie du risque via D, de la même façon.

Modélisez $\Pr(D = 1 \mid A, L, k)$ ***(sur les lignes non censurées, sans exclure*** $D = 1$ ***: c'est lui l'évènement modélisé), avec le même choix de dépendance temporelle qu'en Partie 2 (polynôme en*** k***), et calculez*** `w_net = w_total * 1/cumPred0` ***où*** `cumPred0` ***est le produit cumulé de*** $1 - \Pr(D = 1 \mid \cdot)$.

```
#| context: interactive
## Modele : D ~ A + k + I(k^2) + L1 + L2 + L3 + L4, sur subset(df, C == 0)
## w_net <- w_total * 1 / cumPred0
```

{Correction :}

```
modD <- glm(D ~ A + k + I(k^2) + L1 + L2 + L3 + L4,
            data = subset(df, C == 0), family = binomial)
df$pred0 <- 1 - predict(modD, newdata = df, type = "response")
df <- df |>
  group_by(id) |>
  mutate(cumPred0 = cumprod(pred0)) |>
  ungroup()

w_net <- w_total / df$cumPred0      # risque net : censure x D
summary(w_net)
```

```
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  1.003   1.123   1.294   1.750   1.688  29.459
```

Note

Pourquoi "censure × D" et pas seulement D ? Le poids `w_net` combine deux mécanismes de sortie du risque (la censure C et D), comme on combinait IPTW × IPCW en Partie 1 : ici c'est IPCW-censure × IPCW-D.

3.5 Étape 3 - Effet total et risque net, par IPW

Écrivez une fonction `nonparam_hazard(w, a, event)` qui calcule le hazard non paramétrique pondéré de `event` ("Y" ou "D") pour le bras `a`, et une fonction `chain_CIF(hazY, hazD)` qui chaîne ces hazards en CIF (comme dans la formule de la Partie 2). Utilisez-les pour calculer l'effet total (avec `w_total`, `hazD` inclus) et le risque net (avec `w_net`, sans `hazD`).

```
#| context: interactive
## nonparam_hazard <- function(w, a, event) { ... }
## chain_CIF <- function(hazY, hazD = NULL) { ... }
```

{Correction :}

```
nonparam_hazard <- function(w, a, event = c("Y", "D")) {
  event <- match.arg(event)
  sapply(1:K, function(kk) {
    if (event == "Y") { idx <- df$k==kk & df$A==a & df$C==0 & df$D==0; ev <- idx & df$Y==1 }
    else              { idx <- df$k==kk & df$A==a & df$C==0;           ev <- idx & df$D==1 }
    sum(w[ev]) / sum(w[idx])
  })
}
chain_CIF <- function(hazY, hazD = NULL) {
  S <- 1; cif <- 0
  for (kk in 1:K) {
    hD  <- if (!is.null(hazD)) hazD[kk] else 0
    cif <- cif + S * (1 - hD) * hazY[kk]
    S   <- S * (1 - hD) * (1 - hazY[kk])
  }
  cif
}

ipw_tot_1 <- chain_CIF(nonparam_hazard(w_total, 1, "Y"), nonparam_hazard(w_total, 1, "D"))
ipw_tot_0 <- chain_CIF(nonparam_hazard(w_total, 0, "Y"), nonparam_hazard(w_total, 0, "D"))
ipw_net_1 <- chain_CIF(nonparam_hazard(w_net, 1, "Y"))
ipw_net_0 <- chain_CIF(nonparam_hazard(w_net, 0, "Y"))

c(effet_total = ipw_tot_1 - ipw_tot_0, risque_net = ipw_net_1 - ipw_net_0)
```

```
effet_total  risque_net
-0.06859843 -0.08823124
```

3.6 Étape 4 - Effet séparable, par IPW

L'effet séparable demande un poids "croisé" : pour les patients sous $A = 1$, on transporte leur hazard de D vers ce qu'il serait sous $A = a_D = 0$.

```
#| context: interactive
## predO_aD0 <- 1 - predict(modD, newdata = transform(df, A = 0), type = "response")
## predO_aY1 <- 1 - predict(modD, newdata = transform(df, A = 1), type = "response")
## w_sep <- (cumprod(predO_aD0) / cumprod(predO_aY1)) * w_total  (cumul par individu)
```

{Correction :}

```
predO_aD0 <- 1 - predict(modD, newdata = transform(df, A = 0), type = "response")
predO_aY1 <- 1 - predict(modD, newdata = transform(df, A = 1), type = "response")
w_sep <- (ave(predO_aD0, df$id, FUN = cumprod) / ave(predO_aY1, df$id, FUN = cumprod)) * w_total

## Somme ponderee directe (Stensrud et al., JASA 2022, eq. 11), sur les patients A=1
n_A1 <- sum(df$A[!duplicated(df$id)] == 1)
ipw_sep <- sum(sapply(1:K, function(kk) {
  idx <- df$k==kk & df$A==1 & df$C==0 & df$D==0
  sum(w_sep[idx & df$Y==1]) / n_A1
}))
effet_separable_ipw <- ipw_sep - ipw_tot_0
effet_separable_ipw
```

```
[1] -0.0593796
```

> **Note**
>
> **On utilise ici une somme pondérée directe (Stensrud et al., JASA 2022, éq. 11) plutôt qu'un chaînage hazard/survie : elle évite d'avoir à estimer, en plus, un facteur de survie à D sous a_D, étape plus délicate qu'il n'y paraît.**

3.7 Étape 5 - Comparer g-formula et IPW

Comparez les trois différences de risque obtenues ici (IPW) à celles obtenues en Partie 2 (g-formula).

> **Réponse**
>
> **Les deux estimateurs (modèle des hazards d'un côté, pondération des observations de l'autre) donnent le même ordre entre les trois estimands, en valeur absolue : l'effet est le plus marqué sur le risque net, puis sur l'effet total, puis sur l'effet séparable. Les valeurs peuvent en revanche nettement différer, notamment pour le risque net (−0,068 par g-formula contre −0,088 par IPW). Les deux approches reposent sur des modèles différents (hazards d'un côté, poids de l'autre) et n'ont aucune raison de coïncider sur un échantillon**

de 252 patients.

3.8 Étape 6 - Décomposer l'effet total en direct + indirect

Stensrud et al. (2022) montrent que la somme de l'effet direct séparable et de l'effet indirect séparable (composante A_D seule, à a_Y fixé) reconstruit exactement l'effet total, comme en médiation classique. Reprenez la fonction `gcomp_CIF` de la Partie 2.

Calculez `gcomp_CIF(0, 1)`, puis les deux décompositions : `gcomp_CIF(1,0)-gcomp_CIF(0,0)` + `gcomp_CIF(1,1)-gcomp_CIF(1,0)`, et `gcomp_CIF(0,1)-gcomp_CIF(0,0)` + `gcomp_CIF(1,1)-gcomp_CIF(0,1)`. Vérifiez qu'elles tombent toutes deux exactement sur l'effet total de la Partie 2.

Réponse

Les deux sommes tombent exactement sur l'effet total. Il s'agit d'une identité algébrique ($A - B + B - C = A - C$ sur les 4 coins du carré (a_Y, a_D)), vraie dès qu'on utilise les mêmes deux modèles de hazard pour les 4 combinaisons. Comme en médiation classique, il existe deux décompositions valables, selon la valeur à laquelle on fixe l'autre composante.

4 Conclusion

4.1 Récapitulatif : confusion et censure dépendante (Partie 1)

Analyse	Ajustement	S(36) - A=0	S(36) - A=1	Δ survie
KM brut (non ajusté)	Aucun	0.733	0.809	0.076
IPTW	Score de propension (illustratif, essai randomisé)	0.736	0.805	0.069
G-formula (= risque net)	Modèle de hazard	0.739	0.803	0.064
IPTW × IPCW	Censure dépendante	0.736	0.805	0.069

4.2 Récapitulatif : risques compétitifs et estimands (Parties 2 et 3)

Estimand	Différence de risque, g-formula	Différence de risque, IPW
Effet total	-0.067	-0.069
Risque net	-0.068	-0.088
Effet séparable	-0.055	-0.059

Décomposition	Somme	Effet total (g-formula)
Direct(aD=0) + Indirect(aY=1)	-0.067	-0.067
Indirect(aY=0) + Direct(aD=1)	-0.067	-0.067

4.3 Discussion

Ce que nous apprenons de chaque analyse

— **Analyse brute (Présentation) : l'essai étant randomisé, la différence de survie brute a une interprétation causale sur "Y traité comme seul évènement", mais ce n'est pas la bonne quantité, car D est un risque compétitif, pas une censure ordinaire.**

— **IPTW, g-formula, IPTW × IPCW (Partie 1) : sur un essai randomisé, l'IPTW change peu de choses (pas de confusion réelle) ; l'IPCW ne change rien, car personne n'est censuré avant 36 mois (d'où des lignes IPTW et IPTW × IPCW identiques). Les trois approches restent des exercices utiles pour pratiquer les méthodes, y compris en observationnel où l'IPTW serait indispensable.**

— **CIF naïve vs correcte (Partie 2) : traiter D comme une censure surestime le risque de l'évènement d'intérêt Y, car cela suppose implicitement que les personnes décédées auraient pu, plus tard, faire l'évènement d'intérêt.**
— **Effet total, risque net, effet séparable (Partie 2 et 3) : trois estimands, une seule paire de modèles de hazard (D et Y), combinés différemment. L'effet séparable ne demande pas d'essai à 4 bras : c'est la même g-computation, avec les deux hazards évalués à des bras différents.**
— **G-formula vs IPW (Partie 3) : deux estimateurs très différents dans leur construction donnent le même ordre entre les trois estimands (en valeur absolue), même si les valeurs peuvent nettement différer (risque net notamment).**
— **Décomposition directe/indirecte (Partie 3) : l'effet total se décompose exactement en effet direct + effet indirect séparables, une identité algébrique valable dès qu'on utilise les mêmes deux modèles de hazard pour les 4 combinaisons de (a_Y, a_D).**

Pour vos protocoles

! À retenir

Face à un critère de survie, précisez explicitement dans le protocole : la mesure d'effet choisie (pas seulement un hazard ratio), l'hypothèse retenue sur la censure, et, en présence de risques compétitifs, l'estimand souhaité (effet total, risque net, ou effet séparable). Cette précision s'inscrit directement dans le cadre estimand (ICH E9(R1)) déjà vu : le risque compétitif est un évènement intercurrent à part entière, dont la stratégie de gestion doit être explicitée.